

Büyük Veri ve MLOps Teknolojileri Kullanılarak Deprem Veri Analiz ve Tahmin Sistemi

Ali BAYRAK
Beyza Nur GÜLTEKİN
Çiğdem TUTAR
Şahin AKGÜN
Kocaeli Üniversitesi
Bilgisayar Mühendisliği

Özet—Bu projede Büyük Veri teknolojileri, dağıtık veri işleme sistemleri ve MLOps prensipleri kullanılarak ölçeklenebilir bir deprem analiz ve tahmin sistemi geliştirilmiştir. Sistem içerisinde Apache Kafka ile gerçek zamanlı veri akışı sağlanmış, PySpark ile streaming veri işleme gerçekleştirilmiş ve Bronze, Silver, Gold veri katmanları oluşturulmuştur. Veri ön işleme, veri kalite kontrolü, özellik mühendisliği, makine öğrenmesi model eğitimi, Docker tabanlı servis yönetimi ve görselleştirme süreçleri uygulanmıştır. Yapılan testler sonucunda Random Forest Regression modelinin diğer modellere göre daha başarılı sonuç verdiği görülmüştür.

Index Terms—Büyük Veri, MLOps, Apache Kafka, PySpark, Docker, MongoDB, Makine Öğrenmesi, Deprem Analizi

I. GİRİŞ

Depremler, can ve mal kayıplarına neden olan en önemli doğal afetlerden biridir. Deprem verilerinin düzenli biçimde toplanması, işlenmesi ve analiz edilmesi afet yönetimi açısından büyük önem taşımaktadır. Ancak deprem verileri zamanla yüksek hacimli hale geldiğinden geleneksel veri işleme yöntemleri yetersiz kalabilmektedir.

Bu projede büyük hacimli deprem verilerinin işlenmesi için Büyük Veri teknolojileri kullanılmıştır. Gerçek zamanlı veri akışı için Apache Kafka, dağıtık veri işleme için PySpark, veri depolama için MongoDB ve taşınabilir çalışma ortamı için Docker tercih edilmiştir. Ayrıca makine öğrenmesi modelleri ile deprem büyüklüğü tahmini yapılmıştır.

II. PROJENİN AMACI

Bu projenin temel amacı, deprem verilerini uçtan uca işleyebilen, analiz edebilen ve tahmin üretebilen ölçeklenebilir bir sistem geliştirmektir.

Projenin alt amaçları şunlardır:

- Deprem verilerini streaming yapıda sisteme almak
- Ham verileri Bronze katmanında saklamak
- Verileri Silver katmanında temizlemek
- Gold katmanında modellemeye uygun hale getirmek
- Makine öğrenmesi modelleri ile tahmin üretmek
- Sonuçları grafiklerle görselleştirmek
- Docker ile taşınabilir bir çalışma ortamı oluşturmak

III. SİSTEM MIMARISI

Sistem mimarisi veri akışı odaklı tasarlanmıştır. Veri, Kafka producer tarafından sisteme gönderilmekte, Kafka topic üzerinden PySpark streaming yapısına aktarılmakta ve daha sonra katmanlı veri mimarisi içerisinde işlenmektedir.



IV. KULLANILAN TEKNOLOJİLER

Tablo I
KULLANILAN TEKNOLOJİLER

Teknoloji	Kullanım Amacı
Python	Ana programlama dili
Apache Kafka	Gerçek zamanlı veri akışı
PySpark	Büyük veri işleme
MongoDB	NoSQL veri depolama
Docker	Container yönetimi
Scikit-learn	Makine öğrenmesi modelleri
Pandas	Veri analizi
Matplotlib	Görselleştirme
GitHub	Versiyon kontrol
Jupyter Notebook	Model geliştirme ve analiz

V. VERİ SETİ

Projede kullanılan veri seti deprem kayıtlarından oluşmaktadır. Veri seti içerisinde konum, zaman, derinlik ve büyüklük bilgileri bulunmaktadır.

Tablo II
VERİ SETİ ALANLARI

Alan	Açıklama
Tarih	Deprem gerçekleştiği tarih
Saat	Deprem gerçekleştiği saat
Enlem	Deprem enlem bilgisi
Boylam	Deprem boylam bilgisi
Derinlik	Deprem yer altındaki derinliği
Magnitude	Deprem büyüklük değeri
Bölge	Deprem gerçekleştiği bölge

VI. KAFKA STREAMING ALTYAPISI

Apache Kafka, projede gerçek zamanlı veri aktarımı için kullanılmıştır. Deprem verileri Kafka producer tarafından belirlenen topic içerisine gönderilmiştir. Daha sonra PySpark Streaming bu verileri okuyarak işleme sürecini başlatmıştır.

Kafka producer işlemi örnek olarak aşağıdaki gibidir:

```
producer.send(
    "earthquake_topic",
    value=json.dumps(data).encode("utf-8")
)
```

Kafka kullanımının sağladığı avantajlar:

- Gerçek zamanlı veri akışı
- Yüksek veri hacmini destekleme
- Servisler arası bağımsız iletişim
- Ölçeklenebilir yapı

VII. BRONZE, SILVER VE GOLD VERİ KATMANLARI

Projede modern veri mühendisliği yaklaşımı kullanılarak üç katmanlı veri mimarisi oluşturulmuştur.

A. Bronze Katmanı

Bronze katmanı, ham verilerin ilk olarak saklandığı katmandır. Bu katmanda veri üzerinde minimum işlem yapılmıştır.

Tablo III
BRONZE KATMANI İŞLEMLERİ

İşlem	Açıklama
Veri Alımı	Kafka topic üzerinden veri okunmuştur
Ham Veri Kaydı	Veriler orijinal haliyle saklanmıştır
İlk Kontrol	Veri akışının gelip gelmediği kontrol edilmiştir

B. Silver Katmanı

Silver katmanında veri temizleme ve kalite kontrol işlemleri yapılmıştır.

Tablo IV
SILVER KATMANI İŞLEMLERİ

İşlem	Açıklama
Null Temizliği	Eksik değerler temizlenmiştir
Tip Dönüşümü	Sayısal alanlar uygun tipe çevrilmiştir
Duplicate Temizliği	Yinelenen kayıtlar kaldırılmıştır
Hatalı Veri Filtreleme	Geçersiz değerler ayıklanmıştır

Örnek veri temizleme kodu:

```
df = df.dropna()

df = df.withColumn(
    "magnitude",
    col("magnitude").cast("float")
)
```

C. Gold Katmanı

Gold katmanı, analiz ve makine öğrenmesi için hazırlanmış son veri katmanıdır. Bu katmanda özellik mühendisliği uygulanmıştır.

Tablo V
GOLD KATMANI İŞLEMLERİ

İşlem	Açıklama
Özellik Üretimi	Model için yeni değişkenler oluşturulmuştur
Bölgesel Analiz	Bölge bazı deprem dağılımı çıkarılmıştır
Derinlik Sınıflandırması	Depremler derinliklerine göre sınıflandırılmıştır
Model Verisi	ML modellerine uygun veri hazırlanmıştır

VIII. FEATURE ENGINEERING

Model performansını artırmak için veri setinden yeni özellikler üretilmiştir.

Tablo VI
OLUŞTURULAN ÖZELLİKLER

Özellik	Açıklama
Yıl	Tarih bilgisinden yıl çıkarılmıştır
Ay	Tarih bilgisinden ay çıkarılmıştır
Gün	Tarih bilgisinden gün çıkarılmıştır
Derinlik Kategorisi	Siğ, orta ve derin deprem sınıfları oluşturulmuştur
Bölgesel Yoğunluk	Bölgelere göre deprem yoğunluğu hesaplanmıştır
Ortalama Magnitude	Belirli gruplara göre ortalama büyüklük hesaplanmıştır

IX. MAKİNE ÖĞRENMESİ MODELLERİ

Projede deprem büyüklüğü tahmini için regresyon modelleri kullanılmıştır.

A. Linear Regression

Linear Regression modeli temel karşılaştırma modeli olarak kullanılmıştır. Bu model hızlı çalışmasına rağmen karmaşık ilişkileri öğrenmekte sınırlı kalmıştır.

B. Decision Tree Regression

Decision Tree Regression modeli, verideki doğrusal olmayan ilişkileri öğrenebilmiştir. Ancak tek ağaç yapısı nedeniyle aşırı öğrenme riski bulunmaktadır.

C. Random Forest Regression

Random Forest Regression modeli birden fazla karar ağacından oluşan ensemble bir modeldir. Bu nedenle daha güçlü genelleme yapabilmiş ve en başarılı sonucu üretmiştir.

X. MODEL PERFORMANS KARŞILAŞTIRMASI

Tablo VII
MODEL PERFORMANS SONUÇLARI

Model	RMSE	MAE	R ²
Linear Regression	0.82	0.64	0.71
Decision Tree Regression	0.61	0.49	0.81
Random Forest Regression	0.43	0.31	0.91

Sonuçlara göre Random Forest Regression modeli en düşük hata değerlerine ve en yüksek R² skoruna ulaşmıştır.

XI. DOCKER VE MLOPS SÜRECİ

Projede Docker container mimarisi kullanılarak servislerin izole şekilde çalışması sağlanmıştır. Bu yapı, projenin farklı bilgisayarlarda aynı ortam ile çalıştırılmasını kolaylaştırmıştır.

Tablo VIII
DOCKER SERVİSLERİ

Servis	Görevi
Kafka	Veri akışı yönetimi
Zookeeper	Kafka koordinasyonu
PySpark	Streaming veri işleme
MongoDB	Veri depolama
Jupyter Notebook	Analiz ve model geliştirme

MLOps kapsamında uygulanan işlemler:

- GitHub ile versiyon kontrolü
- Docker ile ortam yönetimi
- Pipeline tabanlı veri işleme
- Model eğitim sürecinin tekrarlanabilir hale getirilmesi
- Test sonuçlarının raporlanması

XII. SİSTEM TESTLERİ

Projede sistem bileşenleri ayrı ayrı test edilmiştir.

Tablo IX
FONKSİYONEL TEST SONUÇLARI

Test	Sonuç
Kafka veri akışı testi	Başarılı
Kafka producer testi	Başarılı
PySpark streaming testi	Başarılı
Bronze katmanı veri kaydı	Başarılı
Silver veri temizleme testi	Başarılı
Gold veri dönüşüm testi	Başarılı
MongoDB bağlantı testi	Başarılı
Docker container testi	Başarılı
Model eğitimi testi	Başarılı
Tahmin üretme testi	Başarılı
Görselleştirme testi	Başarılı

XIII. GÖRSELLEŞTİRME SONUÇLARI

Proje kapsamında deprem verilerinin daha anlaşılır hale getirilmesi için çeşitli grafikler hazırlanmıştır.

Tablo X
GÖRSELLEŞTİRME ÇIKTILARI

Grafik	Açıklama
Magnitude Dağılımı	Deprem büyüklüklerinin dağılımı incelenmiştir
Derinlik Analizi	Depremlerin derinlik dağılımı gösterilmiştir
Bölgesel Yoğunluk	Bölgelere göre deprem yoğunluğu analiz edilmiştir
Gerçek-Tahmin Grafiği	Model tahminleri gerçek değerlerle karşılaştırılmıştır
Zaman Bazlı Analiz	Depremlerin zamana göre dağılımı gösterilmiştir

XIV. EKİP GÖREV DAĞILIMI

XV. COMMIT GEÇMİŞİ

GitHub üzerinde ekip üyelerinin yaptığı ana commit açıklamaları aşağıdaki tabloda verilmiştir.

XVI. SONUÇ

Bu projede Büyük Veri ve MLOps teknolojileri kullanılarak deprem veri analiz ve tahmin sistemi geliştirilmiştir. Apache Kafka ile gerçek zamanlı veri akışı sağlanmış, PySpark ile büyük veri işleme gerçekleştirilmiş ve Bronze, Silver, Gold katmanları ile düzenli veri mimarisi kurulmuştur.

Makine öğrenmesi modelleri karşılaştırılmış ve Random Forest Regression modelinin en başarılı sonuçları verdiği görülmüştür. Docker altyapısı sayesinde sistem taşınabilir hale getirilmiş, GitHub ile versiyon kontrolü sağlanmıştır.

Gelecekte projeye gerçek zamanlı dashboard, bulut tabanlı deployment, otomatik model güncelleme ve derin öğrenme modelleri eklenebilir.

KAYNAKLAR

- [1] Apache Spark Documentation, “Apache Spark,” Available: <https://spark.apache.org/docs/latest/>
- [2] Apache Kafka Documentation, “Apache Kafka,” Available: <https://kafka.apache.org/documentation/>

Tablo XI
EKİP ÜYELERİNİN GÖREVLERİ

Ekip Üyesi	Yaptığı Çalışmalar
Şahin AKGÜN	Docker altyapısı kurulumu, servis konfigürasyonu, container yapısının hazırlanması, ortak modüllerin eklenmesi ve servislerin birlikte çalışacak şekilde düzenlenmesi görevlerini gerçekleştirmiştir.
Beyza Nur GÜLTEKİN	Kafka producer yapısını geliştirmiş, deprem verilerinin Kafka topic içerisine aktarılmasını sağlamış ve Bronze katmanı streaming pipeline yapısını oluşturmuştur.
Çiğdem TUTAR	Silver ve Gold dönüşümlerini gerçekleştirmiş, veri kalite kontrol işlemlerini uygulamış, eksik ve hatalı verileri temizlemiş ve özellik mühendisliği çalışmalarını yapmıştır.
Ali BAYRAK	Makine öğrenmesi modellerini geliştirmiş, model performanslarını karşılaştırmış, görselleştirme notebook'unu hazırlamış ve proje dokümantasyonu ile raporlama sürecini tamamlamıştır.

Tablo XII
COMMIT AÇIKLAMALARI

Ekip Üyesi	Commit Açıklaması
Şahin AKGÜN	Docker altyapısı, servis konfigürasyonu ve ortak modüller eklendi.
Beyza Nur GÜLTEKİN	feat: Kafka producer ve Bronze katmanı streaming pipeline eklendi.
Çiğdem TUTAR	feat: Silver/Gold dönüşümleri, veri kalite kontrolü ve özellik mühendisliği eklendi.
Ali BAYRAK	feat: Makine öğrenmesi modelleri, görselleştirme notebook'u ve proje dokümantasyonu eklendi.

- [3] Docker Documentation, “Docker Docs,” Available: <https://docs.docker.com/>
- [4] MongoDB Documentation, “MongoDB Docs,” Available: <https://www.mongodb.com/docs/>
- [5] Scikit-learn Documentation, “Scikit-learn,” Available: <https://scikit-learn.org/>
- [6] M. Zaharia et al., “Apache Spark: A Unified Engine for Big Data Processing,” Communications of the ACM, vol. 59, no. 11, pp. 56–65, 2016.
- [7] L. Breiman, “Random Forests,” Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
- [8] GitHub Repository, “earthquake-bigdata-mlops,” Available: <https://github.com/sahinakg/earthquake-bigdata-mlops>